软件学院 机器学习 课程实验报告

实验题目: 随机森林 学号: 201700301166

Email: sdyinruichao@163.com

实验目的:

利用随机森林进行鸢尾花数据集的分类

实验软件和硬件环境:

Win10

Pycharm

使用语言: python

使用的库: numpy、math、csv、random

实验原理和方法:

决策树相关理论

特征选取的差异性:每个决策树的 n 个分类特征是在所有特征中随机选择的

投票机制

实验步骤: (不要求罗列完整源代码)

题目分析:

- 1.划分数据集,进行特征划分,给小树不同的特征进行训练,于是我专门写了一个 py 脚本,用于把数据集进行划分,划分出具有不同特征的样本,分别进行训练。
- 2.训练不同的决策树
- 3.得到测试集后对测试集进行测试,得到多个结果后运用投票机制,得到最终的结果

具体工作步骤:

1.数据集划分问题: 我想到的方法是在原有数据具有四维特征的基础上,每一次都去掉一维特征,得到四组数据集,用于训练四个决策树。

```
def loadcsy(name):...
def write csv file(path, head, data):...

# main function

if name ==" main ":
    name = "...\data\iris.csv"
    dataset = loadcsv(name)

for i in range(4):
    fuck = dddvvv(i, dataset)
    write_csv_file("...\data\if\.csv".format(i), None, fuck)
```

2.决策树的训练使用了上一次的代码,因为数据集没有发生改变,所以需要改的地方并不多,直接 for 循环读取四个数据集集,训练出四棵决策树就可以了。

```
# 构建一个树

|def buildTree(dataset, node_id):...

# 构建一个小小树

|def buildTreeR(dataset, node_id, idd):...
```

3.投票时使用数组来保存不同决策树做出的决策,然后使用 多数服从的机制,当出现 2 比 2 时,就在其中选择先进入数 组的那个。

```
def get_panduan(vote):...

def use_vote(dataset):...
```

结论分析与问题:

实验结果:

..\data\i0.csv
验证得知,正确率为96.0%
..\data\i1.csv
验证得知,正确率为98.0%
..\data\i2.csv
验证得知,正确率为97.3333333333333334%
..\data\i3.csv
验证得知,正确率为97.33333333333333333

实验结果分析:

前八行位小决策树做出决策的正确率统计 最后一行是经过投票后,得到的正确率统计。

可以看出,使用集成算法后,比单个算法要好得多,而相较于上次实验,直接使用决策树,(上次的正确率位 98 左右)随机森林也有较大的提升。

实验代码:

```
from math import log
dict_iris = {'Iris-setosa': 0, 'Iris-versicolor': 1, 'Iris-virginica': 2}
dict_siri = {0: 'Iris-setosa', 1: 'Iris-versicolor', 2: 'Iris-virginica'}
    def popfenlei(self, fenlei):
nodes = []
```

```
lef buildTree(dataset, node id):
```

```
# 加载函数
def loadcsv(name):
# 把数据数字化
# 分割函数
```

```
# 计算信息熵
def get_ent(dataset):
def get_gain(dataset, index, dnum):
```

```
gain = entD - a1*get_ent(data1) - a2*get_ent(data2)
# 得到单个特征最高的信息增益所在的分类点
def get_maxgain(dataset, index):
def get_maxtezhengR(dataset, node, idd):
```

```
def get fenleidianR(dataset, idd):
def get fenleidian(dataset):
votes = []
# 验证函数
def classify(dataset, nodes):
```

```
def get_panduan(vote):
def use_vote(dataset):
```

```
def vote(dataset, node):
        vote. append (nnn. YeziPanDuan)
# main function
        digital (dataset)
```

```
dict_iris = {'Iris-setosa': 0, 'Iris-versicolor': 1, 'Iris-virginica': 2}
dict_siri = {0: 'Iris-setosa', 1: 'Iris-versicolor', 2: 'Iris-virginica'}
def loadcsv(name):
```

```
print("Write a CSV file to path %s Successful." % path)
except Exception as e:
    print("Write an CSV file to path: %s, Case: %s" % (path, e))

def dddvvv(num, dataset):
    finalset = []
    for a in dataset:
        aa = []
        for i in range(5):
            if i!=num:
                aa.append(a[i])
        finalset.append(aa)
    return finalset

# main function

if __name__=="__main__":
    name = "..\data\iris.csv"
    dataset = loadcsv(name)
    for i in range(4):
        fuck = dddvvv(i, dataset)
        write_csv_file("..\data\i[).csv".format(i), None, fuck)
```